



République Tunisienne
Ministère de l'Enseignement Supérieur et de la Recherche
Scientifique
Université Tunis El Manar
Faculté des Sciences de Tunis

Rapport de Projet Ingénierie de l'Image

Détection et Classification Automatique des Maladies des Plantes

par Machine Learning et Deep Learning

Réalisé par :

ERRACHI Moedem — IGL4

HAMDENI Louay — IGL4

Encadré par :

Mme. ABED Rahma

Année universitaire : 2025 – 2026

Chapitre 1: Introduction

1.1 Contexte et objectifs

Les maladies des plantes causent des pertes de 20 à 40 % de la production agricole mondiale (FAO, 2019). La vision par ordinateur offre des solutions de diagnostic automatisées, rapides et scalables. Ce projet conçoit une **pipeline complète** : prétraitement → segmentation → extraction de caractéristiques → classification, avec comparaison rigoureuse ML vs Deep Learning.

1.2 Dataset PlantVillage

Nous utilisons les **10 classes de tomate** du dataset PlantVillage (16 011 images totales).




FIGURE 1.1 – Distribution des 10 classes — dataset PlantVillage (tomate).

1.3 Environnement Technique

L'ensemble du projet a été développé en Python. Le tableau ci-dessous récapitule les principales bibliothèques utilisées ainsi que leur rôle dans la pipeline.

Outil	Version	Usage
Python / OpenCV	3.10 / 4.x	Traitement d'images
scikit-learn / scikit-image	1.x / 0.21+	ML classique, GLCM
PyTorch / torchvision	2.x	ResNet18 fine-tuning
FastAPI / React+Vite	0.x / 18.x	Backend API / Frontend

TABLE 1.1 – Environnement technique

Chapitre 2: Prétraitement des Images

2.1 Pipeline

Chaque image brute subit quatre transformations séquentielles avant toute extraction de caractéristiques, comme le résume le tableau ci-dessous.

Étape	Méthode	Objectif
1	Redimensionnement 256×256	Dimensions uniformes
2	Flou Gaussien (5×5)	Réduction du bruit capteur
3	Niveaux de gris	Entrée mono-canal pour GLCM
4	Conversion HSV	Séparation chrominance / intensité

TABLE 2.1 – Étapes du prétraitement

La figure 2.1 illustre ces quatre étapes appliquées à une feuille de tomate saine.




FIGURE 2.1 – Étapes de prétraitement : Original $\rightarrow$ Flou $\rightarrow$ Niveaux de gris $\rightarrow$ HSV.

2.2 Analyse histogrammes et choix de l'espace colorimétrique

Le choix de l'espace colorimétrique conditionne directement la qualité de la segmentation. Les histogrammes de la figure 2.2 montrent que les canaux **Hue** et **Saturation** de l'espace HSV discriminent mieux les trois classes que les canaux RGB natifs.




FIGURE 2.2 – Histogrammes RGB, Hue et Saturation — 3 classes (sain, taches bactériennes, early blight).

Trois espaces ont été évalués ; le tableau 2.2 en résume les avantages et limitations respectifs.

Espace	Avantages	Limitations
RGB	Universel, natif	Canaux corrélés ; sensible à l'éclairage
HSV	Hue encode vert → maladie ; V indépendant de la couleur	Discontinuité autour de $0^\circ/180^\circ$
LAB	Perceptuellement uniforme	Moins intuitif pour le seuillage

TABLE 2.2 – Comparaison des espaces colorimétriques

Justification du choix

HSV retenu : le canal **Hue** sépare l'information chromatique de l'intensité lumineuse, ce qui permet de distinguer directement la transition vert (feuille saine) → jaune/brun (lésion). Contrairement à RGB, les canaux HSV sont faiblement corrélés, et le canal **Value** isole l'illumination — un avantage exploité ultérieurement par CLAHE lors de la segmentation

Chapitre 3: Étude Comparative de la Segmentation

3.1 Méthodes comparées

Quatre méthodes ont été implémentées et comparées sur le sous-ensemble représentatif (9 images) :

- **Otsu** : seuil global sur l'histogramme en niveaux de gris ;
- **HSV+CLAHE** : seuillage par plage Hue [30–95] après normalisation d'illumination ;
- **Combinée (ET)** : intersection des masques Otsu et HSV ;
- **KMeans (k=3)** : clustering des pixels en espace LAB.

Les figures 3.1 et 3.2 illustrent les résultats obtenus sur deux cas représentatifs : une feuille saine et une feuille atteinte de taches bactériennes.




FIGURE 3.1 – Comparaison segmentation — feuille saine : Original / Otsu / HSV+CLAHE ✓ / Combinée / KMeans / Overlay.




FIGURE 3.2 – Comparaison segmentation — taches bactériennes : les zones nécrotiques (brunes) perdues par la méthode combinée.

Le tableau 3.1 résume les performances qualitatives de chaque méthode.

Méthode	Couverture	Bruit	Robustesse	Temps	Choix
Otsu	Élevée (fond inclus)	Moyen	Faible	Rapide	×
HSV+CLAHE	Bonne	Faible	Élevée	Rapide	✓
Combinée (ET)	Conservative	Très faible	Moyenne	Rapide	×
KMeans (k=3)	Variable	Moyen	Moyenne	Lent (×50)	×

TABLE 3.1 – Synthèse comparative des méthodes de segmentation

Justification du choix

HSV+CLAHE retenu. *Otsu* échoue sur les fonds complexes. La *méthode combinée* perd les zones nécrotiques. *KMeans* est 50× plus lent, instable (dépend de l'initialisation) et nécessite une heuristique fragile pour identifier le cluster « feuille » (canal A* minimal en LAB). HSV+CLAHE offre le meilleur équilibre couverture / bruit / robustesse.

3.2 Détection de contours — analyse exploratoire




FIGURE 3.3 – Sobel vs Canny — comparaison exploratoire. Non retenu pour la segmentation (segmentation couleur plus fiable sur PlantVillage).

Chapitre 4: Extraction de Caractéristiques

Chaque image $256 \times 256 \times 3$ est réduite à un **vecteur de 12 descripteurs** calculés sur la zone segmentée :

Groupe	Features	Description	Imp. RF
Couleur HSV (6)	h/s/v_mean + h/s/v_std	Statistiques chromatiques par canal	Élevée
Texture GLCM (3)	contrast, energy, homogeneity	Co-occurrence spatiale (Haralick, 1973)	Moyenne
Forme (3)	area, perimeter, circularity	Morphologie du masque foliaire	Faible

TABLE 4.1 – Vecteur de 12 caractéristiques




FIGURE 4.1 – Importance des caractéristiques (Random Forest, impureté Gini). Les descripteurs HSV dominant.

Les descripteurs de **couleur HSV dominant** (h_mean, s_mean), confirmant que les altérations chromatiques sont les indicateurs principaux des maladies. La texture GLCM apporte une contribution complémentaire ; les descripteurs de forme ont un impact moindre (les feuilles de tomate conservent leur morphologie générale même malades).

Chapitre 5: ML Classique et Deep Learning

5.1 Approche ML classique

Trois modèles entraînés sur 80 % des données (stratifié), évalués sur 20 % + cross-validation k=5 :

Modèle	Accuracy (split)	CV k=5	Entraînement
SVM (RBF, C=1)	81,3 %	$\approx 81 \% \pm 1 \%$	Moyen
Random Forest (100)	80,2 %	$\approx 80 \% \pm 1 \%$	Rapide
KNN (k=5)	78,0 %	$\approx 78 \% \pm 1 \%$	Instantané

TABLE 5.1 – Résultats ML — 10 classes, 16 011 images




FIGURE 5.1 – Matrices de confusion — approche ML classique.

5.2 Approche Deep Learning — ResNet18 fine-tuning

Motivation : le transfer learning exploite les représentations pré-entraînées sur ImageNet (1,2M images) et les adapte à notre tâche. ResNet18 (11,7M paramètres, connexions résiduelles) est léger, rapide et adapté à notre taille de dataset.

Param.	Valeur	Augmentation	Valeur
Couches dégelées	layer4 + fc	RandomResizedCrop	224×224
Optimizer	Adam, lr=3 × 10 ⁻⁴	RandomHorizontalFlip	p=0.5
Époques	10	ColorJitter	brightness/contrast
Batch size	32	Normalisation	ImageNet (mean/std)
Loss	CrossEntropyLoss		

TABLE 5.2 – Hyperparamètres du fine-tuning ResNet18

La figure 5.2 montre l'évolution de la loss et de l'accuracy au cours des 10 époques. On observe une convergence rapide dès les premières époques, avec une loss de validation systématiquement inférieure à celle d'entraînement — signe que le modèle pré-entraîné généralise bien sans sur-apprentissage.




FIGURE 5.2 – Courbes d'entraînement — ResNet18 : loss (gauche) et accuracy (droite) par époque.

La matrice de confusion (figure 5.3) confirme les performances élevées du modèle, avec très peu de confusions inter-classes.




FIGURE 5.3 – Matrice de confusion — ResNet18 fine-tuning (98,2 % accuracy en validation).

Chapitre 6: Résultats, Discussion et Interface Web

6.1 Comparaison ML vs Deep Learning

Le tableau 6.1 confronte les quatre modèles sur plusieurs critères : accuracy, temps d'inférence, dépendance GPU et interprétabilité.

Approche	Modèle	Accuracy	Inférence	GPU requis	Interprétable
ML	SVM (RBF)	81,3 %	<1 ms	Non	Oui
ML	Random Forest	80,2 %	<1 ms	Non	Oui (feat. imp.)
ML	KNN (k=5)	78,0 %	<1 ms	Non	Oui
DL	ResNet18	98,2 %	≈10 ms	Opt.	Partielle

TABLE 6.1 – Synthèse comparative ML vs DL

Le gain de **+16,9 points** (ML→DL) s'explique par les représentations hiérarchiques apprises directement sur les pixels, le prétraitement implicite appris par le réseau, et la capacité bien supérieure du modèle (11,7M paramètres vs 12 features). L'approche ML reste pertinente pour son interprétabilité, sa vitesse d'entraînement et son fonctionnement sans GPU.

6.2 Interface Web

Une interface web interactive a été développée pour valoriser le projet :

Composant	Technologie	Rôle
Frontend	React 18 + Vite	Upload, sélection modèle, affichage résultat
Backend	FastAPI (Python)	API REST, inférence ML/DL, retour JSON
Modèles	joblib + PyTorch	SVM/RF/KNN (.pkl) + ResNet18 (.pth)

TABLE 6.2 – Architecture de l'interface web

Fonctionnalités : upload image (glisser-déposer), choix du modèle, classe prédite + score de confiance, barre de confiance, historique de session, mode sombre.




FIGURE 6.1 – Interface web — upload d'image et résultat de prédiction.

Chapitre 7: Conclusion

Ce projet a produit :

- un pipeline de prétraitement justifié par des comparaisons visuelles.
- une étude comparative de 4 méthodes de segmentation avec rejet documenté de KMeans.
- 12 descripteurs interprétables analysés par feature importance.
- une évaluation rigoureuse ML vs DL avec cross-validation.
- une interface web interactive.

Résultat clé

Résultat principal : ResNet18 (transfer learning) atteint **98,2 %** d'accuracy, soit +16,9 points vs le meilleur classifieur ML (SVM 81,3 %). La segmentation HSV+CLAHE et les 12 descripteurs fournissent une baseline interprétable solide, tandis que le DL offre les meilleures performances absolues.